گزارش تمرین سری سوم

درس داده کاوی

جناب آقای دکتر فراهانی و جناب آقای دکتر خرد پیشه

دستیار محترم جناب آقای علی شریفی

زینب خسروی۹۹۴۲۲۰۶۷

شبکه های پشتیبان در یادگیری ماشین با نظارت هستند .برای طبقه بندی داده ها استفاده می شوند.یکی از مهمترین روش های پیش بینی قوی هستند .مدلی را ایجاد می کنند که نمونه های جدید دسته بندی کند.با به وجود آوردن شکاف یا حاشیه بین دو دسته که هدف این هست که عرض شکاف بین دو دسته را به حداکثر برسانیم.تا با اطمینان بیشتری بگوییم داده در کدام کلاس هست . و سپس نمونه های جدید در همان فضای ترسیم شده پیش بینی کند.

بعضی وقت ها جدا می شوند ولی خطا هم دارند. در این صورت نرم رفتار کردیم یعنی چیزهایی وارد مارجین می شود که جریمه یا خطا در نظر می گیریم که خطاها نباید از حدی بیشتر شوند.باید خطا هم کم شود.

وقتی نمی شود داده ها را از هم جدا کردتوان بالا می بریم بعدفضای ویژگی بالا می رود.غیر خطی میشود ویژگی های جدید اضافه می شود.

حالا داده هایی که داشتیم جدا نمی شدند با این روش توانایی بالا بردیم و از هم جدا می شوند.

کرنل ها مشابه این هست که فیچر اضافه می کردیم. کرنل ها ضابطه های متفاوتی دارند.برای اینکه با خط نمی توانستیم داده ها را از هم جدا کنیم از کرنل ها استفاده می کنیم که خط تبدیل میشود به رویه و داده ها را از هم جدا می کند. و داده ها را کلاس بندی می کند.

بردار های پشتیبان با کرنل های مختلف شکل های مختلف حاصل می شود.اگر بیش از دو کلاس داشته باشیم.ازOVA,OVOاستفاده می کنیم.

با استفاده از ترفند کرنل ی برای طبقه بندی غیر خطی انجان می دهند.

که ورودی ها را در فضای ویژگی هایی با بعد بالا نگاشت می دهند.

وقتی داده ها بدون برچسب هستند یادگیری با نظارت امکان پذیر نیست. رویکرد بدون نظارت نیاز هست داده ها را خوشه بندی می کند.سپس داده های جدید برای این گروه ها ترسیم می کند.هدف این هست که داده جدید در کدام کلاس قرار خواهد گرفت .
درsvm می خواهیم با ابر صفحه نقاط از هم جدا کنیم که به این روش طبقه بندی خطی می گویند.که ابر صفحه های زیادی وجود دارد که داده ها را طبقه بندی میکند. یکی از انتخاب های منطقی به عنوان ابر صفحه این هست که بیشترین حاشیه بین در کلاس نشان دهد .وظایف دیگرش تشخیص نقاط دور افتاده هست بزرگترین فاصله تا نزدیک ترین فاصله داده های آموزشی از هر کلاس بدست می آورد.
در حالی که مسئله اصلی ممکن است که در یک فضای متناهی محدود بیان شود.اغلب اتفاق می افتد که به طور خطی در آن فضا قابل تفکیک نیست.برای همین در فضایی با ابعاد بالاتربر اساس عملکرد هسته یا کرنل ترسیم می شوند .تا تفکیک آن آسانتر شود.
از مجموع هسته ها یا کرنل ها برای اندازه گیری نزدیکی نسبی نقاط به سایر مجموعه ها که تفکیک شده اند استفاده می کنند.
تابع کرنل خطا را به حداقل می رسانند و برای مسائل بهینه سازی مناسب هستند.
پس کرنل مناسب باید انتخاب شود.که داده ها را به بدرستی طبقه بندی کند.و حاشیه حداکثر کند.و خطا به حداقل برساند

توابع کرنلSVM

الگوریتم های svm از مجموعه ای از توابع ریاضی که به عنوان کرنل تعریف می شوند استفاده می کند.وظیفه کرنل این هست که داده ها را به عنوان ورودی گرفته و آنها را به شکل مورد نیاز تبدیل کند.این توابع انواع مختلفی دارند مثال: خطی ، غیرخطی ، و چند جمله ای ، تابع پایه شعاعیRBFسیگموئید.

پرکاربردترین نوع تابع کرنلRBFاست. زیرا دارای پاسخ محلی و متناهی در کل بازه محورX است.

توابع کرنل ، ضرب داخلی بین دو نقطه در یک فضای ویژگی مناسب را برمی گردانند. بنابراین ، با هزینه محاسباتی کم، حتی در فضاهای با ابعاد بالا، مفهومی از شباهت را تعریف می کنند.

.

کرنل چند جمله ای

این کرنل در پردازش تصویر پرکاربرد است. معادله آن به صورت زیر است

$$k(\mathbf{x_i}, \mathbf{x_j}) = (\mathbf{x_i} \cdot \mathbf{x_j} + 1)^d$$

کرنل گاوسی

این یک کرنل برای اهداف عمومی است. و هنگامی که هیچ دانش پیشینی در مورد داده ها وجود ندارد استفاده می شود. معادله آن به صورت زیر است

$$k(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right)$$

تابع پایه شعاعی گاوسیRBF

این کرنل برای اهداف عمومی کاربرد دارد. و هنگامی که هیچ دانش پیشینی در مورد داده ها وجود نداشته باشد، مورد استفاده قرار می گیرد. معادله آن به صورت زیر است

$$k(\mathbf{x_i}, \mathbf{x_j}) = \exp(-\gamma \|\mathbf{x_i} - \mathbf{x_j}\|^2)$$

کرنل RBF لاپلاس

این هم یک کرنل برای اهداف عمومی است. و هنگامی که هیچ دانش پیشینی در مورد داده ها وجود ندارد استفاده می شود. معادله آن به صورت زیر است.

$$k(x,y) = \exp\left(-\frac{||x-y||}{\sigma}\right)$$

کرنل تانژانت هیپربولیک tanh

می توانیم از آن در شبکه های عصبی استفاده کنیم. معادله به صورت زیر است.

$$k(\mathbf{x_i}, \mathbf{x_j}) = \tanh(\kappa \mathbf{x_i} \cdot \mathbf{x_j} + c)$$

کرنل سیگموئید

می توان این کرنل را در شبکه های عصبی مورد استفاده قرار داد. معادله به صورت زیر است.

$$k(x,y) = \tanh(\alpha x^T y + c)$$

کرنل تابع بِسِل

ما می توانیم از آن برای حذف مقطع عرضی در توابع ریاضی استفاده کنیم. معادله آن **به صورت زیر است.**

$$k(x,y) = \frac{J_{v+1}(\sigma||x-y||)}{||x-y||^{-n(v+1)}}$$

کرنل پایه شعاعی ANOVA

ما می توانیم از آن در مسائل رگرسیون استفاده کنیم. معادله مربوط به آن عبارت است

$$k(x,y) = \sum_{k=1}^{n} \exp(-\sigma(x^k - y^k)^2)^d$$

کرنل خطی بصورت یک بعدی spline

این کرنل، هنگام کار با بردارهای بزرگ داده پراکنده ، کاربرد زیادی دارداغلب در دسته بندی متن مورد استفاده قرار می گیرد. در مسائل رگرسیون عملکرد خوبی دارد.معادله به صورت زیر است.

$$k(x,y) = 1 + xy + xy\ min(x,y) - \frac{x+y}{2}\ min(x,y)^2 + \frac{1}{3}\min(x,y)^3$$

الگوریتم ماشین بردار پشتیبان در ابتدا برای ساخت کلاس بندی های باینری ایجاد شد

سپس به عنوان الگوریتمی برای مسائل خوشه بندی و رگرسیون گسترش پیدا کرد.

یک الگوریتم جزئی برای روش های براساس کرنل (هسته) است که ویژگی های برداری را به فضاهای با ابعاد بالاتر نگاشت می کند و این عمل با استفاده از عملکرد کرنل و ساخت یک تابع بهینه خطی دراین فضا یا فضایی چند بعدی که متناسب با داده های آموزشی است، صورت می گیرد.

فضای مابین دو نقطه در فضاهای چند بعدی نیاز به تعریف کرنل دارد. راه حل های ایجاد شده توسط این الگوریتم بهینه هستند. بردارهای ویژگی که به ابر صفحه نزدیک تر هستند، بردارهای پشتیبان نامیده می شوند

موقعیت بردارها بر عملکرد تصمیم گیری تاثیری نخواهد داشت

Soft margin svm بهتر از hardmargin svm

با حاشیه نرم می توان یک مرز تصمیم انتخاب کرد که دارای خطای آموزش غیر صفر باشد حتی اگر داده ها به صورت خطی باشندکه طبقه بندی شان قابل تفکیک هست.

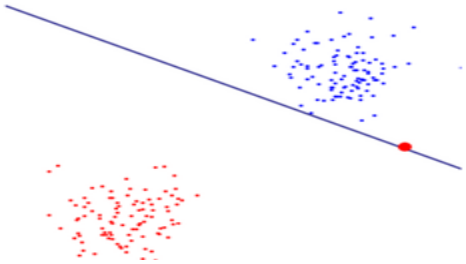

حاشیه سخت

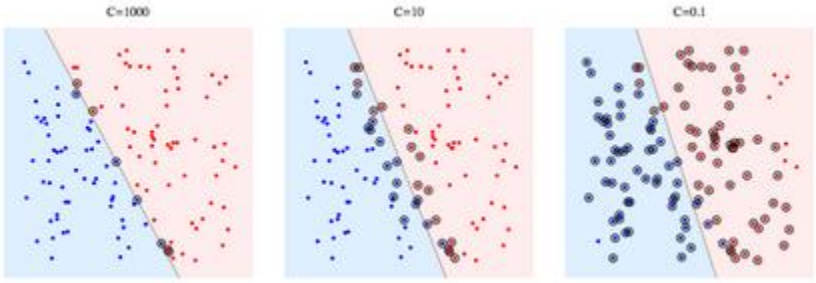

حاشیه سخت بیش از حد به نویز در داده حساس هست.

هدف به حداکثر رساندن حاشیه هست.با حاشیه سخت با یک محدودیت اضافی مواجه هستیمcدر شکل بالا ضریب لاگرانژ هست.که وقتی ۱۰۰۰می شود به حاشیه سخت

نزدیک تر هست.که حاشیه در اینجا تقریبا صفر هست.با حاشیه نرم بهترمی شود در طی مراحل آموزش متغییر های جدید پیش بینی کرد. بنا براین حاشیه سخت نمی تواند تعمیم دهد یا نمی تواند داده های جدید پیش بینی کند.اما حاشیه نرم از قابلیت انعطاف پذیری بیشتری برخوردار هست.

برای کد نویسی پایتون

در ابتدا api tokenاز کگل گرفتم خروجی یک فایل jsonبه گوگل درایو منتقل کردم.

بعد وارد کلب شدم درایوmountکردم.آدرس جایی که فایل قرار دادم تعریف کردم .

و محل کار برایش مشخص کردم. در دیتا ست کگل گزینهcopy api commends

زدم وبعد دستوری که در کگل کپی کردم علامت ! اولش گذاشتم و در کلب ران گرفتم.

در آخر فایل هایی که زیپ بودند با کد دستوری زیر از حالت زیپ خارج کردم.

داده ها را هم دانلود کردم و به صورت دستی در گوگل درایو آپلود کردم.

```
from google.colab import drive
drive.mount('/content/gdrive/')
```

```
Mounted at /content/gdrive/
```

```
[ ]  import os
     os.environ['KAGGLE_CONFIG_DIR'] = "/content/gdrive/MyDrive/kaggle"
```

```
[ ]  !kaggle datasets download -d iabhishekofficial/mobile-price-classification
```

```
Traceback (most recent call last):
  File "/usr/local/bin/kaggle", line 5, in <module>
    from kaggle.cli import main
  File "/usr/local/lib/python2.7/dist-packages/kaggle/__init__.py", line 23, in <mo
    api.authenticate()
  File "/usr/local/lib/python2.7/dist-packages/kaggle/api/kaggle_api_extended.py",
    self.config_file, self.config_dir))
IOError: Could not find kaggle.json. Make sure it's located in /content/gdrive/MyDr
```

```
[ ]  ! unzip/*.zip && rm *.zip
```

```
/bin/bash: unzip/*.zip: No such file or directory
```

```
[ ]
    import pandas as pd
    import numpy as np
    import matplotlib.pyplot as plt
    data = pd.read_csv('/content/gdrive/MyDrive/test.csv')
    data = pd.read_csv('/content/gdrive/MyDrive/train.csv')
```

کتابخانه های مورد استفاده فراخوانی می کنیم.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import ListedColormap
import matplotlib.pyplot as plt
from sklearn import datasets
from sklearn.svm import SVC
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
%pylab inline
```

```
Populating the interactive namespace from numpy and matplotlib
```

```
[ ]  import csv
     import json
     import re
     import numpy as np
     import pandas as pd
     import altair as alt

     from collections import Counter, OrderedDict
     from IPython.display import HTML
```

ابتدا کتابخانه های مهم را برای اجرای بردار های پشتیبان در پروژه استفاده می کنیم.

در مرحله دوم برای پیاده سازی از مجموعه داده() load_iris استفاده می کنیم.

فقط در این تحلیل از طول وعرض استفاده خواهیم کرد.

```
pylab.rcParams['figure.figsize'] = (10, 6)
iris_data = datasets.load_iris()
# We'll use the petal length and width only for this analysis
X = iris_data.data[:, [2, 3]]
y = iris_data.target
# Input the iris data into the pandas dataframe
iris_dataframe = pd.DataFrame(iris_data.data[:, [2, 3]],
                  columns=iris_data.feature_names[2:])
# View the first 5 rows of the data
print(iris_dataframe.head())
# Print the unique labels of the dataset
print('\n' + 'Unique Labels contained in this data are '
     + str(np.unique(y)))
```

```
   petal length (cm)  petal width (cm)
0                1.4               0.2
1                1.4               0.2
2                1.3               0.2
3                1.5               0.2
4                1.4               0.2

Unique Labels contained in this data are [0 1 2]
```

داده ها را با استفاده از تابع()train_test_split به آموزش و تست تقسیم می کنیم.

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=0)
print('The training set contains {} samples and the test set contains {} samples'.format(X_train.shape[0], X_test.shape[0]))
```

```
The training set contains 105 samples and the test set contains 45 samples
```

اکنون داده ها را تجسم می کنیم مشاهده می کنیم که یکی از کلاس ها به صورت خطی قابل تفکیک هست.

```
markers = ('x', 's', 'o')
colors = ('red', 'blue', 'green')
cmap = ListedColormap(colors[:len(np.unique(y_test))])
for idx, cl in enumerate(np.unique(y)):
    plt.scatter(x=X[y == cl, 0], y=X[y == cl, 1],
            c=cmap(idx), marker=markers[idx], label=cl)
```

```
*c* argument looks like a single numeric RGB or RGBA sequence, which should be avoided
*c* argument looks like a single numeric RGB or RGBA sequence, which should be avoided
*c* argument looks like a single numeric RGB or RGBA sequence, which should be avoided
```

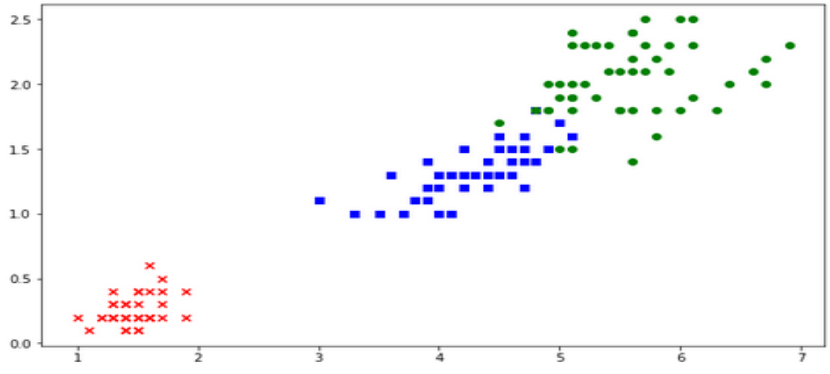

سپس داده ها را مقیاس گذاری کنیم مقیاس بندی این اطمینان میدهد که تمام مقادیر داده ها در یک محدوده مشترک قرار دارند.

```
[47] standard_scaler = StandardScaler()
     standard_scaler.fit(X_train)
     X_train_standard = standard_scaler.transform(X_train)
     X_test_standard = standard_scaler.transform(X_test)
     print('The first five rows after standardisation look like this:\n')
     print(pd.DataFrame(X_train_standard, columns=iris_dataframe.columns).head())
```

```
The first five rows after standardisation look like this:

   petal length (cm)  petal width (cm)
0          -0.182950         -0.293181
1           0.930661          0.737246
2           1.042022          1.638870
3           0.652258          0.350836
4           1.097702          0.737246
```

بعد از اینکه داده ها را پیش پردازش کردیم مرحله بعد پیاده سازی مدل بردار پشتیبان هست از کتابخانهsklearnاستفاده می کنیم با کرنلrbf

```
[49] SVM = SVC(kernel='rbf', random_state=0, gamma=.10, C=1.0)
     SVM.fit(X_train_standard, y_train)
```

```
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma=0.1, kernel='rbf',
    max_iter=-1, probability=False, random_state=0, shrinking=True, tol=0.001,
    verbose=False)
```

بعد از اینکه دقت خودش بدست آورد بهترین کار تجسم مدل هستبا تابعی به نام Decision_plot()انجام دهیم.

```
[50] import warnings
     def versiontuple(version):
        return tuple(map(int, (version.split("."))))
     def decision_plot(X, y, classifier, test_idx=None, resolution=0.02):
        # setup marker generator and color map
        markers = ('s', 'x', 'o', '^', 'v')
        colors = ('red', 'blue', 'green', 'gray', 'cyan')
        cmap = ListedColormap(colors[:len(np.unique(y))])
        # plot the decision surface
        x1min, x1max = X[:, 0].min() - 1, X[:, 0].max() + 1
        x2min, x2max = X[:, 1].min() - 1, X[:, 1].max() + 1
        xx1, xx2 = np.meshgrid(np.arange(x1min, x1max, resolution),
                               np.arange(x2min, x2max, resolution))
        Z = classifier.predict(np.array([xx1.ravel(), xx2.ravel()]).T)
        Z = Z.reshape(xx1.shape)
        plt.contourf(xx1, xx2, Z, alpha=0.4, cmap=cmap)
        plt.xlim(xx1.min(), xx1.max())
        plt.ylim(xx2.min(), xx2.max())
        for idx, cl in enumerate(np.unique(y)):
           plt.scatter(x=X[y == cl, 0], y=X[y == cl, 1],
                       alpha=0.8, c=cmap(idx),
                       marker=markers[idx], label=cl)
```

```
[51] decision_plot(X_test_standard, y_test, SVM)
```

```
*c* argument looks like a single numeric RGB or RGBA sequence, which should be avoided a
*c* argument looks like a single numeric RGB or RGBA sequence, which should be avoided a
*c* argument looks like a single numeric RGB or RGBA sequence, which should be avoided a
```

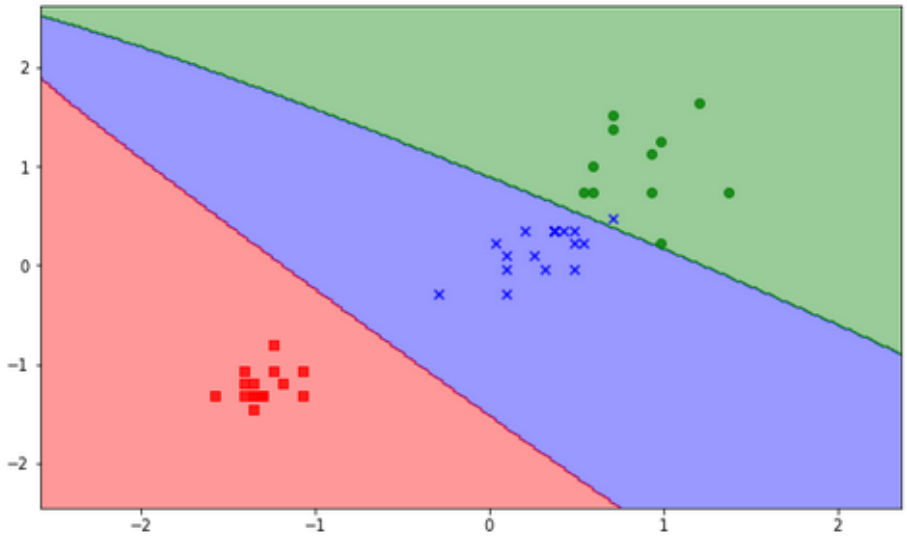

داده فراخوانی می کنیم.

```
] data
```

	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memory	m_dep	mobile_w
0	842	0	2.2	0	1	0	7	0.6	18
1	1021	1	0.5	1	0	1	53	0.7	13
2	563	1	0.5	1	2	1	41	0.9	14
3	615	1	2.5	0	0	0	10	0.8	13
4	1821	1	1.2	0	13	1	44	0.6	14
...	...	...	...	...	...	...	...	...	.
1995	794	1	0.5	1	0	1	2	0.8	10
1996	1965	1	2.6	1	0	0	39	0.2	18
1997	1911	0	0.9	1	1	1	36	0.7	10
1998	1512	0	0.9	0	4	1	46	0.1	14
1999	510	1	2.0	1	5	1	45	0.9	16

2000 rows × 21 columns

اطلاعات دیتا بدست می آوریم.

```
[ ] data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2000 entries, 0 to 1999
Data columns (total 21 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   battery_power   2000 non-null   int64
 1   blue            2000 non-null   int64
 2   clock_speed     2000 non-null   float64
 3   dual_sim        2000 non-null   int64
 4   fc              2000 non-null   int64
 5   four_g          2000 non-null   int64
 6   int_memory      2000 non-null   int64
 7   m_dep           2000 non-null   float64
 8   mobile_wt       2000 non-null   int64
 9   n_cores         2000 non-null   int64
 10  pc              2000 non-null   int64
 11  px_height       2000 non-null   int64
 12  px_width        2000 non-null   int64
 13  ram             2000 non-null   int64
 14  sc_h            2000 non-null   int64
 15  sc_w            2000 non-null   int64
 16  talk_time       2000 non-null   int64
 17  three_g         2000 non-null   int64
 18  touch_screen    2000 non-null   int64
 19  wifi            2000 non-null   int64
 20  price_range     2000 non-null   int64
dtypes: float64(2), int64(19)
memory usage: 328.2 KB
```

شمارش دیتا میانگین استاندارد مینیمم و ماکسیمم بدست می آوریم.

```
[ ]  data.describe()
```

	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memor
count	2000.000000	2000.0000	2000.000000	2000.000000	2000.000000	2000.000000	2000.0000
mean	1238.518500	0.4950	1.522250	0.509500	4.309500	0.521500	32.0465
std	439.418206	0.5001	0.816004	0.500035	4.341444	0.499662	18.1457
min	501.000000	0.0000	0.500000	0.000000	0.000000	0.000000	2.0000
25%	851.750000	0.0000	0.700000	0.000000	1.000000	0.000000	16.0000
50%	1226.000000	0.0000	1.500000	1.000000	3.000000	1.000000	32.0000
75%	1615.250000	1.0000	2.200000	1.000000	7.000000	1.000000	48.0000
max	1998.000000	1.0000	3.000000	1.000000	19.000000	1.000000	64.0000

نوع دیتا را مشخص می کنیم.

```
[ ]  data.dtypes
```

```
battery_power      int64
blue               int64
clock_speed      float64
dual_sim           int64
fc                 int64
four_g             int64
int_memory         int64
m_dep            float64
mobile_wt          int64
n_cores            int64
pc                 int64
px_height          int64
px_width           int64
ram                int64
sc_h               int64
sc_w               int64
talk_time          int64
three_g            int64
touch_screen       int64
wifi               int64
price_range        int64
dtype: object
```

داده های پوچ پیدا می کنیم.

```
[ ]  data.isnull().sum()
```

```
battery_power    0
blue             0
clock_speed      0
dual_sim         0
fc               0
four_g           0
int_memory       0
m_dep            0
mobile_wt        0
n_cores          0
pc               0
px_height        0
px_width         0
ram              0
sc_h             0
sc_w             0
talk_time        0
three_g          0
touch_screen     0
wifi             0
price_range      0
dtype: int64
```

بعد اندازه دیتا بدست می آوریم

```
[ ]  data.shape
```

```
(2000, 21)
```

نرمال سازی میکنیم تا داده های پرت حذف کند.بعد انداز داده که می گیریم کم می شود.

```
[ ]  for cols in data.columns:
         if data[cols].dtype == 'int64' or data[cols].dtype == 'float64':
              data[cols] = ((data[cols] - data[cols].mean())/(data[cols].std()))
```

```
[ ]  for cols in data.columns:
         if data[cols].dtype == 'int64' or data[cols].dtype == 'float64':
             upper_range = data[cols].mean() + 3 * data[cols].std()
             lower_range = data[cols].mean() - 3 * data[cols].std()

             index = data[(data[cols]> upper_range)|(data[cols]< lower_range)].index
             data = data.drop(index)
```

```
[ ]  data.shape
```

```
(1988, 21)
```

عنوان ویژگی ها

```
[ ]  data.head()
```

	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memory	m_dep
0	-0.902372	-0.989802	0.830572	-1.018929	-0.762304	-1.043705	-1.380298	0.340654
1	-0.495015	1.009798	-1.252751	0.980932	-0.992642	0.957646	1.154735	0.687376
2	-1.537302	1.009798	-1.252751	0.980932	-0.531966	0.957646	0.493422	1.380820
3	-1.418964	1.009798	1.198217	-1.018929	-0.992642	-1.043705	-1.214970	1.034098
4	1.325574	1.009798	-0.394912	-1.018929	2.001753	0.957646	0.658751	0.340654

نمودار زیر همبستگی بین ویژگی ها را نشان می دهد.

```
[ ]  import seaborn as sns
     import matplotlib.pyplot as plt
     corr=data.corr()
     fig = plt.figure(figsize=(15,12))
     r = sns.heatmap(corr, cmap='Purples')
     r.set_title("Correlation ")
```

```
Text(0.5, 1.0, 'Correlation ')
```

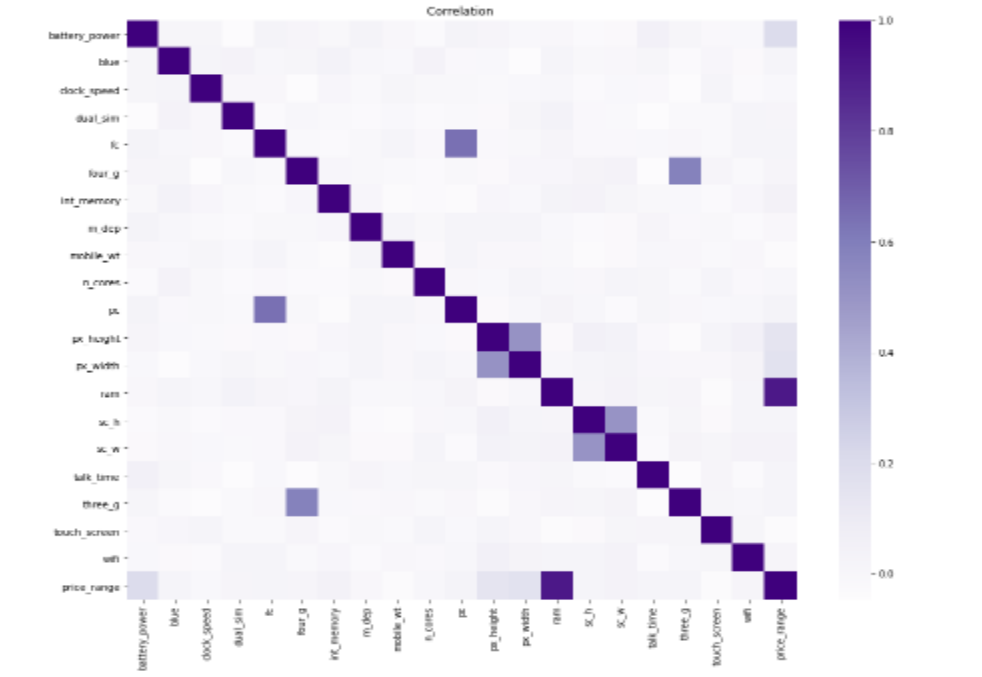

با این نمودارپایین چک می کنیم که که در دیتاست دادها یا مقدارشونmiss

شده یا نه یعنی مقدارش نداشته باشیم که در این جا همه داده ها هستند.

```
[ ] import missingno as msno
    import matplotlib.pyplot as plt
    msno.bar(data)
    plt.show()
```

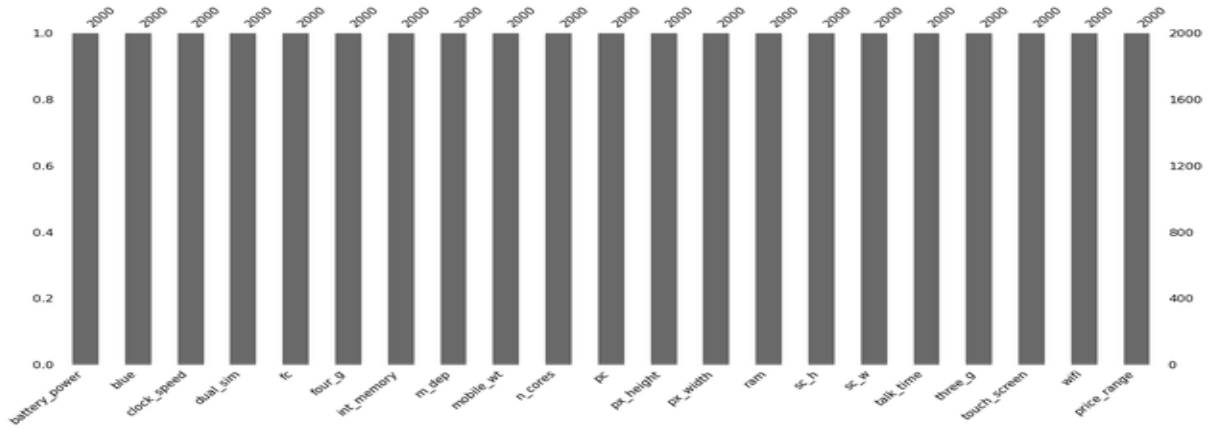

دیتاست کلاس بندی قیمت موبایل در کگل بود کدsvmبا استفاده از پکیجsklearn

```
[ ] import numpy as np
    from sklearn.model_selection import train_test_split
    labels = data['price_range']
    features=data.drop('price_range',axis=1)
    x_train,x_test,y_train,y_test = train_test_split(features,labels,test_size=0.2,random_sta
```

```
[ ] from sklearn import svm
    clf = svm.SVC(kernel='linear', C=1,gamma=1)
```

مهندسی ویژگی

باید ویژگی های مناسبی از داده یا باز نمایی مناسب تری از داده داشته باشیم تا مدل عملکرد بهتری برای حل مسئله داشته باشد.و مدل بهتر و دقیق تر عمل کند.

در این قسمت باید خلاقیت زیاد باشد تا ویژگی ها را از داده ها بسازیم. برای هر کدام از داده ها تکنیک هایی برای مهندسی ویژگی هست.

مشکلی که هست این هست که بعد مسئله بالا می برد پیچیده گی مسئله هم بالا می برد .

راه کاربردی برای تبدیل ویژگی کتگوریکال به داده مقداری استفاده از:

One hot encoding

یک ویژگی داریم k مقدارمی تواند داشته باشد . از برداری به طولk استفاده می کنیم

برای مدل هایی که خطی هستند استفاده می شود.فضا یا حافظه زیادی اشغال میکند.

و اگر داده ای را نداشته باشیم مقدارش نداریم دیگه نمی توانیم از این روش استفاده کنیم .روش به این صورت هست که برای ویژگی مون برداری در نظر می گیریم به اندازه ی انواعی که داریم که مربوط به هر کدام بود یک می کنیم و بقیه صفر می شود.

ویژگی های عددی بهبود ببخشیم. یعنی ویژگی های بیشتربه نفع مدل بدست آوریم.

خود داده های عددی ممکنه به همان شکل که هستند به درد ما نخورند .مثلا رند

```
chart=alt.Chart(data).mark_circle(size=20).encode(
    x='ram',
    y='battery_power',
    color='price_range:N',
    tooltip=["price_range", "ram",'battery_power']
).interactive().properties(
    width=400, height=300
)
```

میکنیم.که متغییر عددی تبدیل می شود به کتگوریکال

کار دیگه ای که انجام می دهیمbinning:

با بخش بخش کردن متغییر پیوسته تبدیل می کنیم به متغییر گسسته

داده ها را با فرایند کد کردن تغییر بدهیم تا در مدل خوب کار کند.و داده های پرت از بین ببریم. با این روش داده های پرت مدیریت می کنیم.

کریلیشن مقدار ویژگیprice_range نسبت به بقیه ویژگی ها

```
[ ]  corr.sort_values(by=["price_range"],ascending=False).iloc[0].sort_values(ascending=
```

```
price_range       1.000000
ram               0.917046
battery_power     0.200723
px_width          0.165818
px_height         0.148858
int_memory        0.044435
sc_w              0.038711
pc                0.033599
three_g           0.023611
sc_h              0.022986
fc                0.021998
talk_time         0.021859
blue              0.020573
wifi              0.018785
dual_sim          0.017444
four_g            0.014772
n_cores           0.004399
m_dep             0.000853
clock_speed      -0.006606
mobile_wt        -0.030302
touch_screen     -0.030411
Name: price_range, dtype: float64
```

ویژگی*PRICE RANGE AND RAM*را *Binning* می کنیم

کلاس کم هزینه وکلاس هزینه متوسط وکلاس هزینه بالاو کلاس هزینه بسیار بالا

```
chart=alt.Chart(data).mark_bar().encode(
    alt.X('ram', bin=True),
    y='count(*):Q',
    color='price_range:N',
).facet(column='price_range:N')
```

```
chart=alt.Chart(data).mark_bar().encode(
    alt.X('ram', bin=True),
    y='count(*):Q',
    color='battery power:N',
).facet(column='battery power:N')
```

svm با کرنل RBF

```
[ ]  from sklearn.svm import SVC
     model_svc = 'support vector classifier'
     svc = SVC(C=2, kernel='rbf')
```

به طور کلی برای مطابقت داده ها با نرمال بودن از log transform استفاده می کنند.

توزیع نرمال به شکل زنگوله ای هست.توزیع متقارن هست.

اغلب داده های بدست آمده در مطالعات واقعی کج ومعوج هستند.که تحلیل آماری استاندارد از این داده ها نتایج نامعتبری هستند.

داده های تبدیل شدهlog transform اگردر داده های اصلی از توزیع نرمال پیروی کنند.داده های تبدیل شده هم از توزیع نرمال پیروی می کنند.

از هر روشی که استفاده می شود داده های انحرافی کنار می گذارند.برای وقتی کاربرد دارد که به توزیع داده ها وابسته نیستند.برای مقابله با داده های انحرافی هست.اگر در همه موارد استفاده می شود باید بسیار محتاطانه اعمال شود.

در این دیتاست نمی شود log transformاستفاده کرد چون که داده های اصلی از از توزیع نرمال پیروی نمی کنند.

برای اضافه کردن فیچرمساحت ویژگی طول را در ویژگی عرض ضرب می کنیم.

برای اضافه کردن فیچر حجم ویژگی طول درویژگی عرض در ویژگی ارتفاع ضرب می کنیم.

حاشیه نرم در ماشین بردار پشتیبان با استفاده sklwarnطبقه بندی ساده خطی ازانجام می دهد.با بردار پشتیبان سعی می کند خطا به حدقل برساند.و حاشیه سختری ایجاد کند.

```
[ ]  import numpy
     from scipy import optimize

     class SVM2C(object):
         def __init__(self,xdata,ydata,c=200.,learning_rate=0.01,
                      n_iter=5000,method='GD'):

             self.values=numpy.unique(ydata)
             self.xdata=xdata
             self.ydata=numpy.where(ydata==self.values[-1],1,-1)
             self.c=c
             self.lr=learning_rate
             self.n_iter=n_iter
             self.method=method

             self.m=len(xdata)
             self.theta=numpy.random.random(xdata.shape[1])-0.5

         def costFunc(self,theta,x,y):
             zs=numpy.dot(x,theta)
             j=numpy.maximum(0.,1.-y*zs).mean()*self.c+0.5*numpy.sum(theta**2)
             return j
```

```
def jac(self,theta,x,y):
    '''Derivative of cost function'''
    zs=numpy.dot(x,theta)
    ee=numpy.where(y*zs>=1.,0.,-y)[:,None]
    # multiply rows by ee
    dj=(ee*x).mean(axis=0)*self.c+theta
    return dj

def train(self):

    #----------Optimize using scipy.optimize----------
    if self.method=='optimize':
        opt=optimize.minimize(self.costFunc,self.theta,args=(self.xdata,self.ydata),
                jac=self.jac,method='BFGS')
        self.theta=opt.x

    #---------Optimize using Gradient descent---------
    elif self.method=='GD':
        costs=[]
        lr=self.lr

        for ii in range(self.n_iter):
            dj=self.jac(self.theta,self.xdata,self.ydata)
            self.theta=self.theta-lr*dj
            cii=self.costFunc(self.theta,self.xdata,self.ydata)
            costs.append(cii)

        self.costs=numpy.array(costs)

    return self
```

```
    def predict(self,xdata):

        yhats=[]
        for ii in range(len(xdata)):
            xii=xdata[ii]
            yhatii=xii.dot(self.theta)
            yhatii=1 if yhatii>=0 else 0
            yhats.append(yhatii)
        yhats=numpy.array(yhats)

        return yhats



#-------------Main----------------------------------
if __name__=='__main__':

    xdata = numpy.array([[-1, -1], [-2, -1], [1, 1], [2, 1]])
    ydata = numpy.array([1, 1, 2, 2])

    mysvm=SVM2C(xdata,ydata,method='GD')
    mysvm.train()

    from sklearn import svm
    clf=svm.SVC(C=50,kernel='linear')
    clf.fit(xdata,ydata)

    print ('mysvm.theta')
    print clf.coef_

    #-------------------Plot-------------------------
```

```
    #-------------------Plot-------------------------
    import matplotlib.pyplot as plt
    figure=plt.figure(figsize=(12,10),dpi=100)
    ax=figure.add_subplot(111)

    cmap=plt.cm.jet
    nclasses=numpy.unique(ydata).tolist()
    colors=[cmap(float(ii)/len(nclasses)) for ii in nclasses]

    #----------------Plot training data----------------
    for ii in range(len(ydata)):
     xii=xdata[ii][0]
        yii=xdata[ii][1]
        colorii=colors[nclasses.index(ydata[ii])]
        ax.plot(xii,yii,color=colorii,marker='o')
```

```
import numpy
from scipy import optimize

class SVM2C(object):
    def __init__(self,xdata,ydata,c=9000,learning_rate=0.001,
            n_iter=600,method='GD'):

        self.values=numpy.unique(ydata)
        # Add 1 dimension for bias
        self.xdata=numpy.hstack([xdata,numpy.ones([xdata.shape[0],1])])
        self.ydata=numpy.where(ydata==self.values[-1],1,-1)
        self.c=c
        self.lr=learning_rate
        self.n_iter=n_iter
        self.method=method

        self.m=len(xdata)
        self.theta=numpy.random.random(self.xdata.shape[1])-0.5

    def costFunc(self,theta,x,y):
        zs=numpy.dot(x,theta)
        j=numpy.maximum(0.,1.-y*zs).mean()*self.c+0.5*numpy.sum(theta[:-1]**2)
        return j

    def jac(self,theta,x,y):
        '''Derivative of cost function'''
        zs=numpy.dot(x,theta)
        ee=numpy.where(y*zs>=1.,0.,-y)[:,None]
        dj=numpy.zeros(self.theta.shape)
        dj[:-1]=(ee*x[:,:-1]).mean(axis=0)*self.c+theta[:-1] # weights
        dj[-1]=(ee*self.c).mean(axis=0)                     # bias
        return dj

    def train(self):

        #----------Optimize using scipy.optimize----------
        if self.method=='optimize':
            opt=optimize.minimize(self.costFunc,self.theta,args=(self.xdata,self.ydata),
                    jac=self.jac,method='Nelder-Mead')
            self.theta=opt.x

        #---------Optimize using Gradient descent---------
        elif self.method=='GD':

            costs=[]
            lr=self.lr
            # ADAM parameteres
            beta1=0.9
            beta2=0.999
            epsilon=1e-8

            mt_1=0
            vt_1=0
            for ii in range(self.n_iter):
                t=ii+1
                dj=self.jac(self.theta,self.xdata,self.ydata)
                '''
                mt=beta1*mt_1+(1-beta1)*dj
                vt=beta2*vt_1+(1-beta2)*dj**2
                mt=mt/(1-beta1**t)
                vt=vt/(1-beta2**t)
```

یک ویژگی جدید به نام مساحت ساختم

```
[51]
     df['square']=df['px_width']*df['px_height']
```

ماشین های بردار پشتیبان از روش های یادگیری نظارت شده هستند که برای طبقه بندی رگرسیون و تشخیص داده های پرت استفاده می شود.

از مزایای استفاده اش در فضا هایی با ابعاد بالا موثر هست برای عملکرد تصمیم گیری داده های آموزشی استفاده می شود از نظر حافظه کارامد هست.

از توابع هسته برای عملکرد تصمیم گیری استفاده می شود. تنظیم هسته بسیار مهم هست که از کدام هسته برای کدام داده استفاده شود. تخمین های احتمالاتی مستقیم

ارائه نمی دهد. از اعتبار سنجی برای بررسی مدل استفاده می شود.

اول داده های ترین وتست تقسیم می کنیم. بعد نحوه ی تقسیم بندی کلاس هارا بررسی می کنیم.

```
[ ]  y = data["price_range"].values
     x_data=data.drop(["price_range"],axis=1)
     x = (x_data-np.min(x_data))/(np.max(x_data)-np.min(x_data))
     from sklearn.model_selection import train_test_split
     x_train, x_test, y_train, y_test = train_test_split(x,y,test_size = 0.2,random
```

```
[ ]  from yellowbrick.target import ClassBalance
     visualizer = ClassBalance(labels=[0, 1, 2,3])
     ClassBalance(y_train, y_test)
     visualizer.poof()
```

تعدادکلاس ها تقریبا یکسان هست.

مدل اول

```
[ ]  from sklearn.svm import SVC
     svm=SVC(random_state=1)
     SVC(x_train,y_train)
```

```
SVC(C=      battery_power  blue  clock_speed  ...  three_g  touch_screen  wifi
409          0.818303   1.0          0.16  ...      1.0           0.0   1.0
30           0.720107   1.0          0.00  ...      0.0           0.0   1.0
1150         0.251169   0.0          0.32  ...      1.0           0.0   0.0
1949         0.171009   1.0          0.16  ...      1.0           1.0   0.0
424          0.142953   0.0          0.72  ...      0.0           0.0   0.0
...               ...   ...           ...  ...      ...           ...   ...
1800         0.572478   0.0          0.48  ...      1.0           0.0   0.0
1099         0.798931   0.0          0.00  ...      1.0           1.0   0.0
1944         0.028724   1.0          0.00  ...      1.0           1.0   0.0
237          0.812959   1.0          0.80  ...      1.0           1.0   1.0
1064         0.915832   0.0          0.00  ...      1.0           0.0   1.0

[1590 rows x 20 columns],
    break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='scale',
    kernel=array([ 0.44710178,  1.34130533,  0.44710178, ..., -1.34130533,
         1.34130533, -0.44710178]),
    max_iter=-1, probability=False, random_state=None, shrinking=True,
    tol=0.001, verbose=False)
```

وقتی از کتابخانه اسکالرن دقت در مدل اول در داده های تست و ترین داریم.

حالا می خواهیم این دقت افزایش بدهیم اول ویژگی های غیر ضروری کم می کنیم.

تا دقت بهبود دهیم.بهترین ویژگی ها برای طبقه بندی انتخاب می کنیم.

از روش کلاس بندی آنووا برای تعیین بهترین ویژگی ها استفاده میکنیم.

```
from sklearn.feature_selection import SelectKBest
from sklearn.feature_selection import f_classif
accuracy_list_train = []
k=np.arange(1,21,1)
for each in k:
 SVC(x_train, y_train)
accuracy_list_train.append(SVC)

plt.plot(color="green",label="train")

plt.xlabel("k values")
plt.ylabel("train accuracy")
plt.legend()
plt.show()
```

```
No handles with labels found to put in legend.
```

از این ویژگی ها استفاده می کنیم.

```
df = {'best features number': k, 'train_score': accuracy_list_train}
```

```
[ ] selector = SelectKBest(f_classif, k = 5)
    x_new = selector.fit_transform(x_train, y_train)
    x_new_test=selector.fit_transform(x_test,y_test)
    names_train = x_train.columns.values[selector.get_support()]
    names_test = x_test.columns.values[selector.get_support()]
    print("x train features:",names_train)
    print("x test features:",names_test)
```

```
x train features: ['battery_power' 'px_height' 'px_width' 'ram' 'sc_h']
x test features: ['battery_power' 'px_height' 'px_width' 'ram' 'sc_h']
```

برای استفاده از الگوریتم بردار های پشتیبان باید برخی پارامتر هایش تنظیم شود.

```
from sklearn.model_selection import GridSearchCV

C=[1,0.1,0.25,0.5,2,0.75]
kernel=["linear","rbf"]
gamma=["auto",0.01,0.001,0.0001,1]
decision_function_shape=["ovo","ovr"]
```

بعد از استفاده از بهترین پارامترها هسته rbf از هسته خطی هم استفاده می کنیم.

```
[ ] svm=SVC(random_state=1)
    grid_svm=GridSearchCV(estimator=svm,cv=5,param_grid=dict(kernel=kernel,C=C, ga
```

```
[ ] from sklearn.model_selection import StratifiedKFold
    from yellowbrick.model_selection import CVScores
    _, ax = plt.subplots()

    cv = StratifiedKFold(10)

    oz = CVScores(
        SVC(C=2,decision_function_shape="ovo",gamma="auto",kernel="linear",random_
    )
    oz.poof()
```

```
No handles with labels found to put in legend.
```

از اعتبار سنجی برای بررسی بردار های پشتیبان استفاده می کند.

```
[ ]  svm_model=SVC(C=2,decision_function_shape="ovo",gamma="auto",kernel="linear",
```

```
[ ]  from yellowbrick.classifier import ConfusionMatrix
     cm = ConfusionMatrix(
         svm_model, classes=[0,1,2,3]
     )

     cm.poof()
```

```
[ ]  svm_test=x_test[["battery_power","int_memory","px_height","px_width","ram"]]
```

```
svm_test.head()
```

	battery_power	int_memory	px_height	px_width	ram
1556	0.249833	0.661290	0.460204	0.313084	0.839123
1552	0.708751	0.854839	0.526531	0.851802	0.491716
1182	0.138945	0.177419	0.290816	0.615487	0.056387
112	0.244489	0.032258	0.035714	0.983979	0.142704
564	0.048764	0.580645	0.145918	0.447931	0.805184

تا مدل پیش بینی کند ویژگی ها را مقادیر واقعی با مقایدر پیش بینی شده تفاوت ها را بررسی می کنیم دقتش بدست می آورد خطا.به صورت بالابدست می آید.

برای ارزیابی الگوریتم از چهار مقیاس استفاده می کنیم.

دقت:چه تعدادبه درستی توسط مدل پیش بینی شده اند.

نرخ خطا :چه تعداد به اشتباه پیش بینی شده اند.

منفی غلط:چه تعداد تشخیص داده نشده اند.

مثبت غلط:چه تعداد به اشتباه دسته بندی شده اند.

نتیجه:

برای بدست آوردن بهترین نتیجه در تحلیل داده ها باید تعداد مثبت صحیح به بالاترین برسد. یعنی داده ها به درستی تقسیم شده اند .و مثبت غلط به پایین ترین تعداد برسد.